

## §6 平均、分散、標準偏差

### 6.1 平均值 (期待値)

(i)  $X$  の平均値:  $m = E(X) = \begin{cases} \sum x_i p_i & (\text{離散的}) \\ \int_{-\infty}^{\infty} x f(x) dx & (\text{連続的}) \end{cases}$

(ii)  $E(g(X)) = \begin{cases} \sum g(x_i) p_i & (\text{離散的}) \\ \int_{-\infty}^{\infty} g(x) f(x) dx & (\text{連続的}) \end{cases}$

(iii)  $E(a_1 X_1 + \dots + a_k X_k + b) = a_1 E(X_1) + \dots + a_k E(X_k) + b$  ( $a_1, \dots, a_k, b$ : 定数)

(iv)  $X_1, X_2, \dots, X_k$  が独立  $\Rightarrow E(X_1 X_2 \dots X_k) = E(X_1) E(X_2) \dots E(X_k)$

### 6.2 分散, 標準偏差

(i)  $X$  の分散:  $\sigma^2 = V(X) = E[(X - E(X))^2] = E(X^2) - E^2(X)$

(ii)  $X$  の標準偏差:  $\sigma = \sqrt{V(X)} = \sqrt{E(X^2) - E^2(X)} \quad (\geq 0)$

(iii)  $V(aX + b) = a^2 V(X)$

(iv)  $X_1, \dots, X_k$  が独立  $\Rightarrow V(a_1 X_1 + \dots + a_k X_k + b) = a_1^2 V(X_1) + \dots + a_k^2 V(X_k)$

### 6.3 共分散, 相関係数

(i) 共分散:  $Cov(aX, bY) = ab Cov(X, Y)$   $Cov(X_1 + X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$

$Cov(X_1, X_2) = \sigma_{X_1 X_2} = E[(X_1 - E(X_1))(X_2 - E(X_2))] = E(X_1 X_2) - E(X_1) E(X_2)$

(ii) 相関係数:  $\rho_{X_1 X_2} = \frac{\sigma_{X_1 X_2}}{\sigma_{X_1} \sigma_{X_2}} = \frac{Cov(X_1, X_2)}{\sigma_{X_1} \sigma_{X_2}}$  (iii)  $V(X_1 + X_2) = V(X_1) + V(X_2) + 2Cov(X_1, X_2)$

(iv)  $X_1, X_2$  が独立  $\Rightarrow Cov(X_1, X_2) = 0$

$V(X_1 + X_2) = V(X_1) + V(X_2)$

(v)  $X_1, X_2, \dots, X_n$  に対し  $Cov(X_i, X_j) = \sigma_{ij} = \sigma_{ji}$   $\rho_{ij} = \rho_{ji} = \rho_{X_i X_j}$ ,  $\rho_{ii} = 1$

$(\sigma_{ij}) = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1n} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} & \sigma_{n2} & \dots & \sigma_{nn} \end{bmatrix}$   $(\rho_{ij}) = \begin{bmatrix} \rho_{11} & \rho_{12} & \dots & \rho_{1n} \\ \rho_{21} & \rho_{22} & \dots & \rho_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{n1} & \rho_{n2} & \dots & \rho_{nn} \end{bmatrix}$  共分散行列  
相関係数行列

確率変数  $X$ , 期待値  $E(X) = \mu$ , 分散  $V(X) = \sigma^2$

Chebyshev 不等式:  $P\{|X - \mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}$  (チェビシェフ不等式)

$E(X^k)$   $X$  の  $k$  階原点矩  $E(X^k Y^l)$   $X$  と  $Y$  の  $k, l$  階混合矩  
 $E[(X - E(X))^k]$   $X$  の  $k$  階中心矩  $E[(X - E(X))^k (Y - E(Y))^l]$   $X$  と  $Y$  の  $k, l$  階混合中心矩

$C_{11} = E[(X_1 - E(X_1))^2]$   $(\begin{smallmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{smallmatrix})$  共分散行列

$C_{22} = E[(X_2 - E(X_2))^2]$

$C_{21} = E[(X_2 - E(X_2))(X_1 - E(X_1))]$

$C_{12} = E[(X_1 - E(X_1))(X_2 - E(X_2))]$

## §7 大数法則と中心極限定理

### 7.1 大数の(弱)法則

確率変数  $X_1, X_2, \dots, X_n$  が独立,  $E(X_i) = \mu$ ,  $V(X_i) = \sigma^2$ ,  $\bar{x} = \frac{1}{n} \sum_{i=1}^n X_i$ ,  $\varepsilon > 0$  のとき  
 $\lim_{n \rightarrow \infty} P(|\bar{x} - \mu| \geq \varepsilon) = 0$

$\Rightarrow$  Bernoulli 大数法則  $f_n$  は  $n$  回独立重复試験中事件  $A$  发生的次数,  $p$  は事件  $A$  在每次试验中发生的概率, 对任意正数  $\varepsilon > 0$ , 有

$\lim_{n \rightarrow \infty} P\left|\left|\frac{f_n}{n} - p\right| \geq \varepsilon\right| = 0$

### 7.2 中心極限定理

確率変数  $\{X_i\}$  が同一分布に従い, 互いに独立で,  $E(X_i) = \mu$ ,  $V(X_i) = \sigma^2$  ( $i=1, 2, \dots, n$ ) のとき

$\lim_{n \rightarrow \infty} P\left(\frac{X_1 + X_2 + \dots + X_n - n\mu}{\sqrt{n}\sigma} \leq x\right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt = N(0, 1) \Rightarrow \bar{x} \sim N(\mu, \sigma^2/n)$

### 7.3 Lyapunov 定理

確率変数  $\{X_i\}$  が互いに独立で,  $E(X_k) = \mu_k$ ,  $V(X_k) = \sigma_k^2 > 0$

$\frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{\sqrt{\sum_{k=1}^n \sigma_k^2}} \sim N(0, 1) \Rightarrow \sum_{k=1}^n X_k \sim N\left(\sum_{k=1}^n \mu_k, \sum_{k=1}^n \sigma_k^2\right)$

### 7.4 De Moivre-Laplace 定理

確率変数  $\{n\}$  が二項分布  $B(n, p)$  に従い

$\lim_{n \rightarrow \infty} P\left\{\frac{\eta_n - np}{\sqrt{np(1-p)}} \leq x\right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)$

例  $X_k = 0 \quad p = 0.05$   $P(X > 450) = ?$   $\frac{X_k}{p_k} \begin{matrix} 0 & 1 & 2 \\ 0.05 & 0.8 & 0.15 \end{matrix}$   $E(X_k) = 1.1$   
 $X_k = 1 \quad p = 0.8$   
 $X_k = 2 \quad p = 0.15$   $D(X_k) = 0.19$

(2)  $Y \sim b(400, 0.8)$   $P\{X > 450\} = P\left\{\frac{X - 400 \times 0.8}{\sqrt{400 \times 0.8 \times 0.2}} > \frac{450 - 400 \times 0.8}{\sqrt{400 \times 0.8 \times 0.2}}\right\}$   
 $P\{Y \leq 340\}$   
 $= P\left\{\frac{Y - 400 \times 0.8}{\sqrt{400 \times 0.8 \times 0.2}} \leq \frac{340 - 400 \times 0.8}{\sqrt{400 \times 0.8 \times 0.2}}\right\}$   
 $\approx \Phi(2.5) = 0.9938$

分布:

I. ガンマ分布  $\Gamma(\lambda, \infty)$

(i) 確率密度関数:  $f(x) = \begin{cases} \frac{\alpha^\lambda}{\Gamma(\lambda)} x^{\lambda-1} e^{-\alpha x} & (0 < x) \\ 0 & (x \leq 0) \end{cases}$  ( $\alpha > 0, \lambda > 0$ ) (ii) 平均値  $= \frac{1}{\alpha}$   
分散  $= \frac{1}{\alpha^2}$

II.  $\chi^2$  分布  $\chi^2(n)$

(i) 確率密度関数:  $f(x) = \begin{cases} \frac{1}{2^{n/2} \Gamma(n/2)} x^{n/2-1} e^{-x/2} & (0 < x) \\ 0 & (x \leq 0) \end{cases}$  (自由度  $n$ ) (ii) 平均値  $= n$   
分散  $= 2n$

III.  $t$  分布 (学生  $t$ -分布)  $t(n)$

(i) 確率密度関数:  $f(x) = \frac{1}{\sqrt{n}} \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})} \left(1 + \frac{x^2}{n}\right)^{-(n+1)/2}$  (ii) 平均値  $= 0$  ( $n > 1$ )  
分散  $= n/(n-2)$  ( $n > 2$ )

IV.  $F$  分布 (ファットーカ分布)  $F(m, n)$

(i) 確率密度関数:  $f(x) = \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2}) \Gamma(\frac{n}{2})} \frac{x^{m/2-1}}{(1+x)^{(m+n)/2}}$  ( $0 < x$ ) (ii) 平均値  $= \frac{n}{n-2}$  ( $n > 2$ )  
分散  $= \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}$  ( $n > 4$ )

## §8 参数估计

总体  $X$  の分布函数  $F(x; \theta)$  の形式已知,  $\theta$  が待估参数.  $X_1, X_2, \dots, X_n$  が  $X$  の一个样本,  $x_1, x_2, x_3, \dots$  が相应样本值.  $\hat{\theta}(x_1, x_2, \dots, x_n)$  が  $\theta$  の估计值

(I) 矩估计法

$\begin{cases} \mu_1 = E(X) = \mu_1(\theta_1, \theta_2, \dots, \theta_k) \\ \mu_2 = E(X^2) = \mu_2(\theta_1, \theta_2, \dots, \theta_k) \\ \vdots \\ \mu_k = E(X^k) = \mu_k(\theta_1, \theta_2, \dots, \theta_k) \end{cases}$  可以解出  $\begin{cases} \theta_1 = \theta_1(\mu_1, \mu_2, \dots, \mu_k) \\ \theta_2 = \theta_2(\mu_1, \mu_2, \dots, \mu_k) \\ \vdots \\ \theta_k = \theta_k(\mu_1, \mu_2, \dots, \mu_k) \end{cases}$  用  $A_i = \frac{1}{n} \sum_{j=1}^n X_j^i$  替换对应  $\mu_i$  即可

(II) 最大似然估计法

在参数  $\theta$  的情况下, 事件  $\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\}$  发生的概率为  $L(\theta) = L(x_1, x_2, \dots, x_n; \theta)$   
当  $\theta = \theta_0$  使  $L(\theta)$  取到最大值时  
将  $\theta_0$  这一值称为最大似然估计值. 常从方程  $\frac{d}{d\theta} L(\theta) = 0$  中解得  
对数似然方程  $\frac{d}{d\theta} \ln L(\theta) = 0$

多参数  $\theta_1, \theta_2, \dots, \theta_k$  情况:

$\frac{\partial}{\partial \theta_i} L = 0, i=1, 2, \dots, k$   $\frac{\partial}{\partial \theta_i} \ln L = 0, i=1, 2, \dots, k$  对数似然方程组

最大似然估计的不变性

设  $\theta$  的函数  $u = u(\theta)$   $L(x_1, x_2, \dots, x_n; \theta) = \max L(x_1, x_2, \dots, x_n; \theta(u))$

8.3 估计量的评选标准

(i) 无偏性 估计量  $\hat{\theta}$  的数学期望存在, 且  $E(\hat{\theta}) = \theta$  ( $\theta$  为待估参数) 则  $\hat{\theta}$  为  $\theta$  的无偏估计量

总体  $X$  均值为  $\mu$ , 方差为  $\sigma^2 > 0$  未知

样本  $\bar{x}$  及  $S^2$  为总体均值  $\mu$  的无偏估计

样本方差  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{x})^2$  为总体方差  $\sigma^2$  的无偏估计

$k$  阶样本矩  $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$  是  $k$  阶总体矩  $\mu_k$  的无偏估计量

(2) 有效性

如果在样本容量  $n$  相同的情况下,  $\hat{\theta}_1$  较  $\hat{\theta}_2$  更密集的在真值  $\theta$  附近. 我们就认为  $\hat{\theta}_1$  较  $\hat{\theta}_2$  合理

若  $\hat{\theta}_1$  与  $\hat{\theta}_2$  都是  $\theta$  的无偏估计量,  $D(\hat{\theta}_1) < D(\hat{\theta}_2)$ , 则称  $\hat{\theta}_1$  较  $\hat{\theta}_2$  有效.

(3) 相合性

若对于任意  $\varepsilon > 0$ , 当  $n \rightarrow \infty$  时  $\hat{\theta}(x_1, x_2, \dots, x_n)$  依概率收敛于  $\theta$ , 则称  $\hat{\theta}$  为  $\theta$  的相合估计量

8.4 区间估计

置信区间: 两个统计量  $\underline{\theta} = \underline{\theta}(x_1, x_2, \dots, x_n)$ ,  $\bar{\theta} = \bar{\theta}(x_1, x_2, \dots, x_n)$   $\underline{\theta} < \bar{\theta}$

$P\{\underline{\theta}(x_1, x_2, \dots, x_n) < \theta < \bar{\theta}(x_1, x_2, \dots, x_n)\} \geq 1 - \alpha$   
( $\underline{\theta}, \bar{\theta}$ ) 是  $\theta$  的置信水平为  $1 - \alpha$  的置信区间 函数  $W = W(x_1, x_2, \dots, x_n; \theta)$  的分布  
 $\underline{\theta}$  置信下限  $1 - \alpha$  称为置信水平 不依赖于  $\theta$  以及其他未知参数, 称该函数为枢轴量. 例 正态分布转化为  $N(0, 1)$   
 $\bar{\theta}$  置信上限